KORELASYON, KONVOLÜSYON, PROJEKSİYON, SEGMENTASYON

Korelasyon

İki imge arasındaki ilişkinin bulunmasında ya da bir imgenin içerisinde önemli bir bilginin aranmasında kullanılır. Konvolüsyondan farklı olarak kerneldeki katsayılar doğrudan kendi konumlarına karşılık gelen piksel değerleri ile çarpılmaktadır.

$$g(x,y) = \sum_{k=-n}^{n} \sum_{j=-m}^{m} h(j,k) f(x+j, y+k)$$

Normalizasyon için:

$$g'(x,y) = \frac{\sum_{k=-n}^{n} \sum_{j=-m}^{m} h(j,k) f(x+j, y+k)}{\sum_{k=-n}^{n} \sum_{j=-m}^{m} f(x+j, y+k)}$$

Korelasyon Katsayısı

$$\overline{g_r} = \frac{\sum_{j=1}^{n}\sum_{k=1}^{m} g_r(x_j, y_k)}{n \quad m}$$

$$\overline{g_i} = \frac{\sum_{j=1}^{n}\sum_{k=1}^{m} g_i(x_j, y_k)}{n \quad m}$$

$$\sigma_r = \sqrt{\frac{\sum_{j=1}^{n}\sum_{k=1}^{m} [g_r(x_j, y_k) - \overline{g_r}]^2}{n \quad m \quad - 1}}$$

$$\sigma_i = \sqrt{\frac{\sum_{j=1}^{n}\sum_{k=1}^{m} [g_i(x_j, y_k) - \overline{g_i}]^2}{n \quad m \quad - 1}}$$

$$\sigma_{ri} = \frac{\sum_{j=1}^{n}\sum_{k=1}^{m} [\{g_r(x_j, y_k) - \overline{g_r}\} \{g_i(x_j, y_k) - \overline{g_i}\}]}{n \quad m \quad - 1}$$

$$\rho = \frac{\sigma_{ri}}{\sigma_r \quad \sigma_i}$$

Korelasyon Katsayısı

- Korelasyon katsayısı -1 - +1 aralığında değer alır
- $\rho = 0$ herhangi bir benzerlik olmadığını
- $\rho = -1$ ters yönlü benzerliği (örn. Aynı görüntünün ait diapozitif ve negatifleri)
- $\rho = 1$ tam eşleşmeyi (mümkün olan en büyük benzerlik değeri)

ifade etmektedir.

Korelasyon ve Konvolüsyon Arasındaki Farklar

Difference Between Correlation & Convolution Filtering		
	Correlation Filtering	Convolution Filtering
Rotating Kernel	The kernel is not rotated	The kernel is rotated
Formula	$G[i,j] = \sum_{u=-k}^{k} \sum_{v=-k}^{k} H[u,v]F[i+u, j+v]$	$G[i,j] = \sum_{u=-k}^{k} \sum_{v=-k}^{k} H[u,v]F[i-u, j-v]$
Notation	$G = H \otimes F$	$G = H \star F$

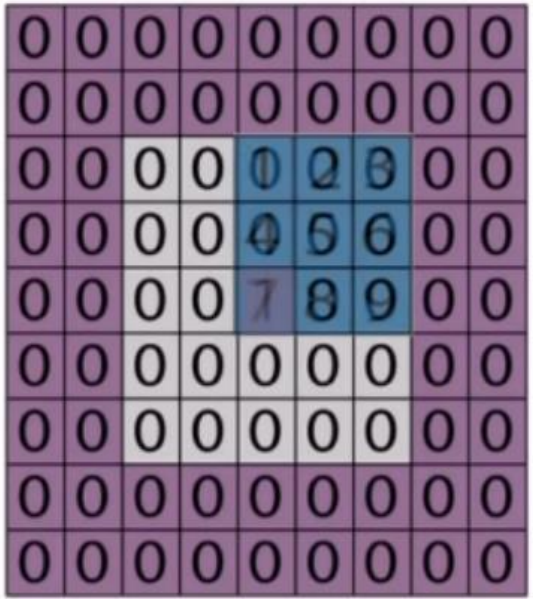
Korelasyon

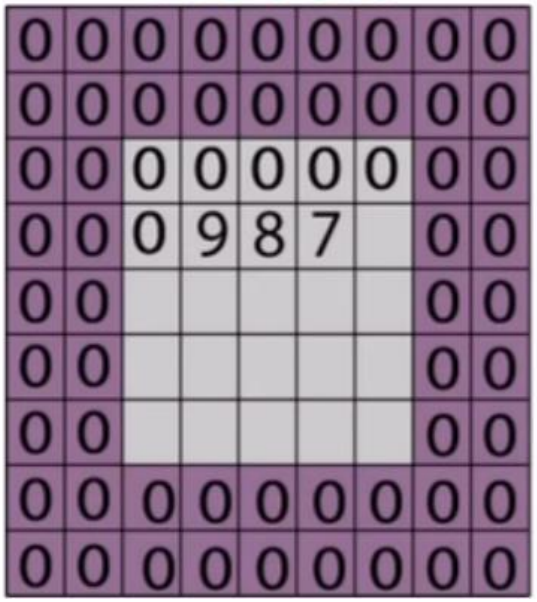
Function

0	0	0	0	0
0	0	0	0	0
0	0	1	0	0
0	0	0	0	0
0	0	0	0	0

Mask

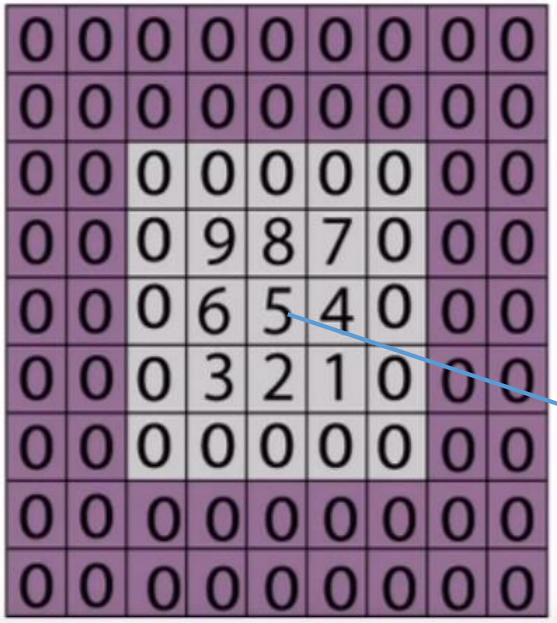
1	2	3
4	5	6
7	8	9





Korelasyon

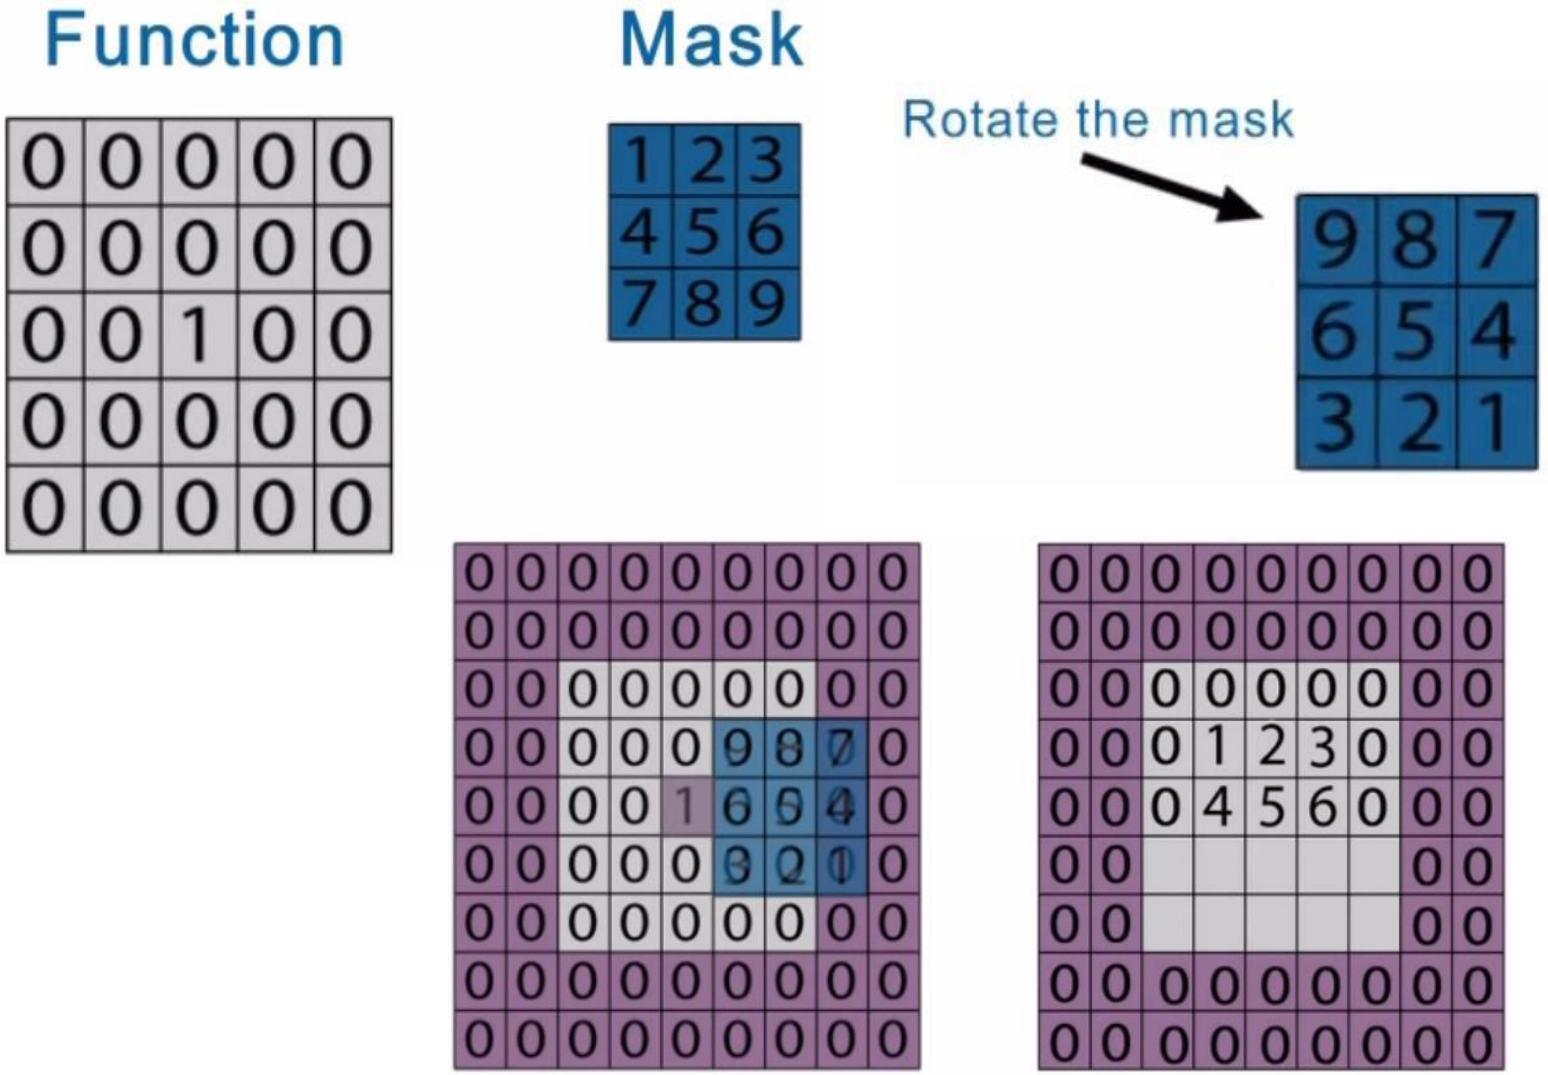
Final Correlation Result



Cropped Correlation Result

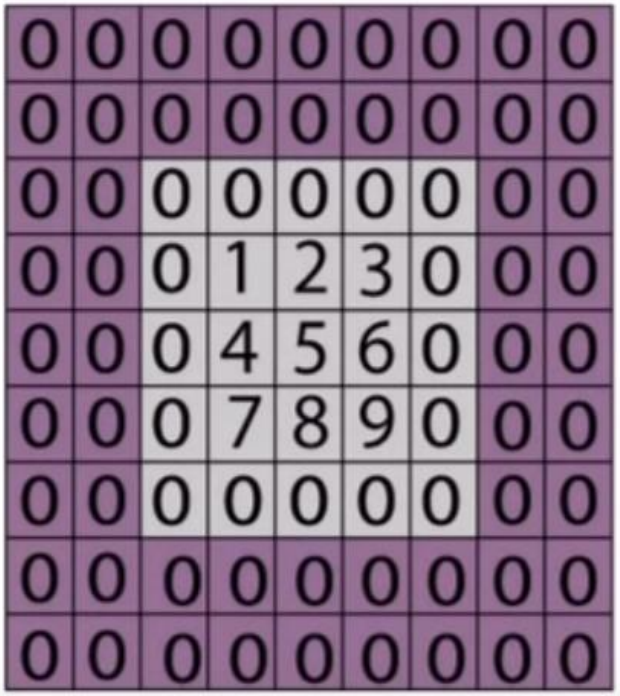
0	0	0	0	0
0	9	8	7	0
0	6	5	4	0
0	3	2	1	0
0	0	0	0	0

Konvolüsyon



Konvolüsyon

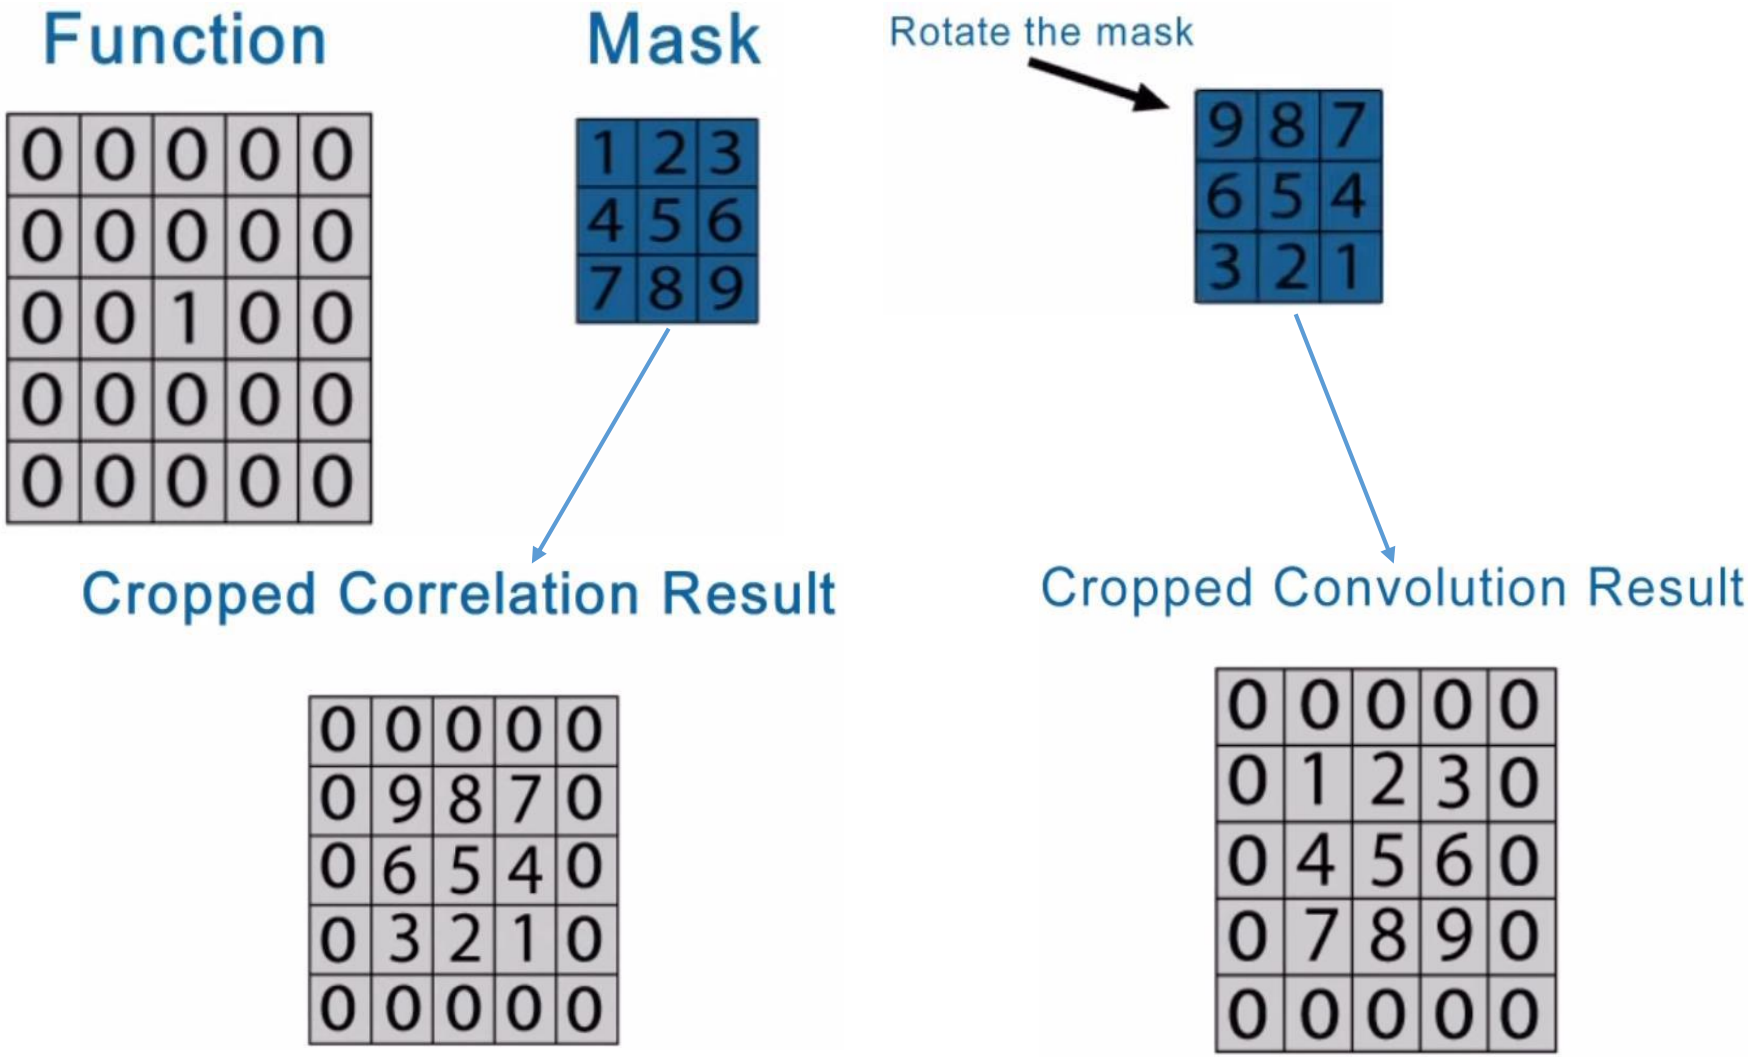
Final Convolution Result



Cropped Convolution Result

0	0	0	0	0
0	1	2	3	0
0	4	5	6	0
0	7	8	9	0
0	0	0	0	0

Konvolüsyon-Korelasyon



0	0	0	0	0
0	0	0	0	0
0	0	1	0	0
0	0	0	0	0
0	0	0	0	0

1	2	3
4	5	6
7	8	9

9	8	7
6	5	4
3	2	1

0	0	0	0	0
0	9	8	7	0
0	6	5	4	0
0	3	2	1	0
0	0	0	0	0

0	0	0	0	0
0	1	2	3	0
0	4	5	6	0
0	7	8	9	0
0	0	0	0	0

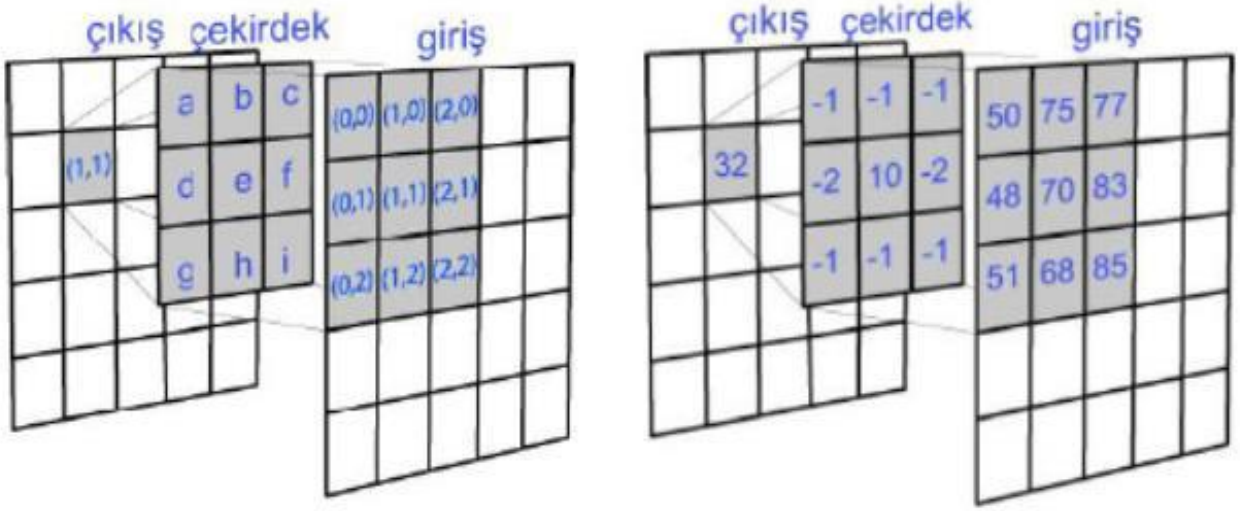
Konvolüsyon

- Konvolüsyon; yumuşatma, keskinleştirme, kenar belirleme gibi görüntü işleme fonksiyonlarını gerçekleştirmede çok sık kullanılmaktadır.
- Konvolüsyonda bir pikselin yeni değeri kendisinin ve çevresindeki piksellerin ağırlıklı ortalaması ile bulunmaktadır. Konvolüsyon şablonu (Filtre matrisi-kernel) uygulamaya göre farklı boyutlarda olabilmekle beraber genelde 3x3 lük bir matristir.

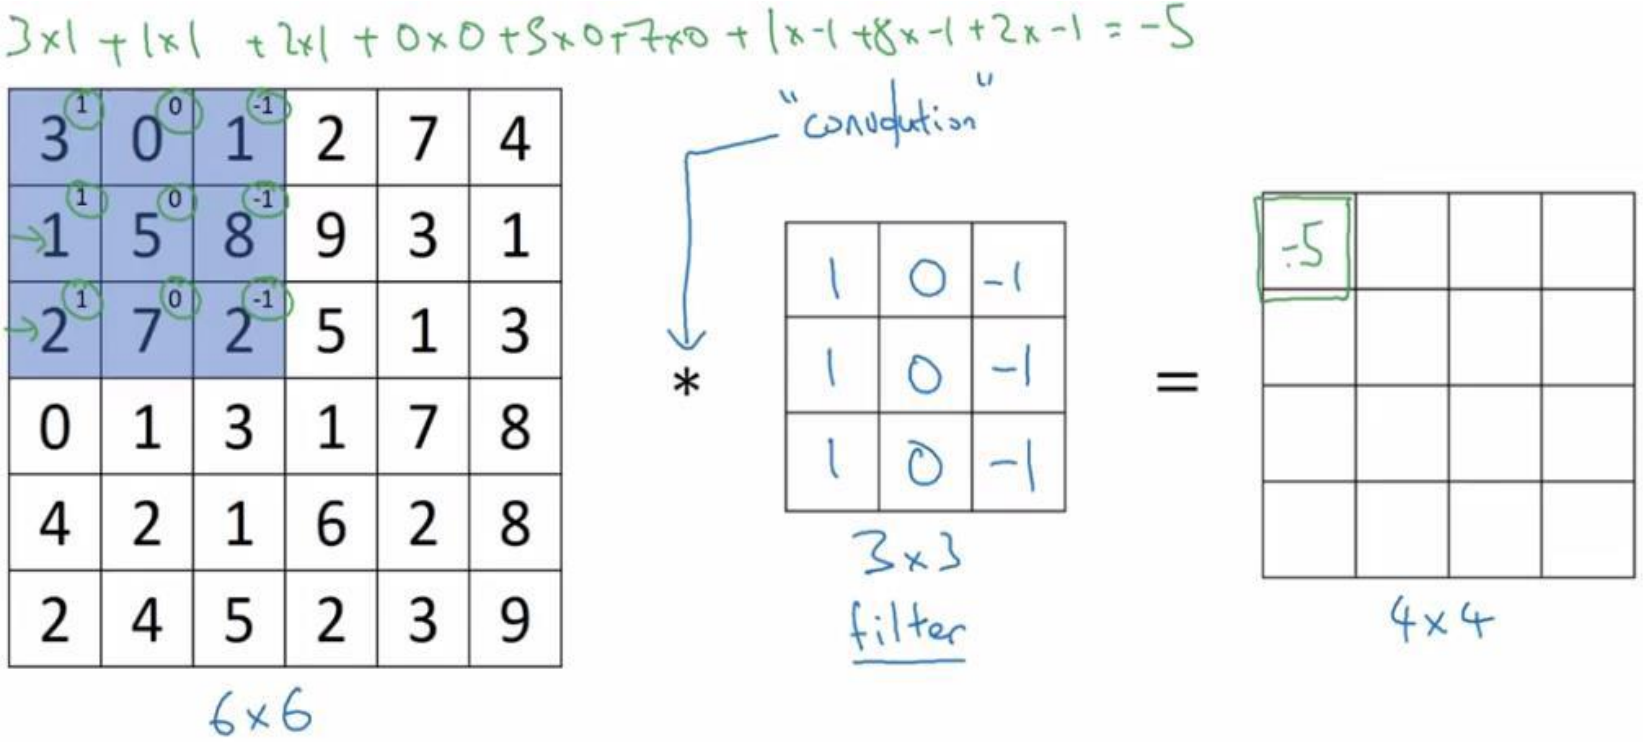
Konvolüsyon

$$imge = \begin{bmatrix} i(0,0) & i(0,1) & i(0,2) \\ i(1,0) & i(1,1) & i(1,2) \\ i(2,0) & i(2,1) & i(2,2) \end{bmatrix} = \begin{bmatrix} 55 & 75 & 77 \\ 48 & 70 & 83 \\ 51 & 68 & 85 \end{bmatrix} \quad çekirdek = \begin{bmatrix} -1 & -1 & -1 \\ -2 & 10 & -2 \\ -1 & -1 & -1 \end{bmatrix}$$

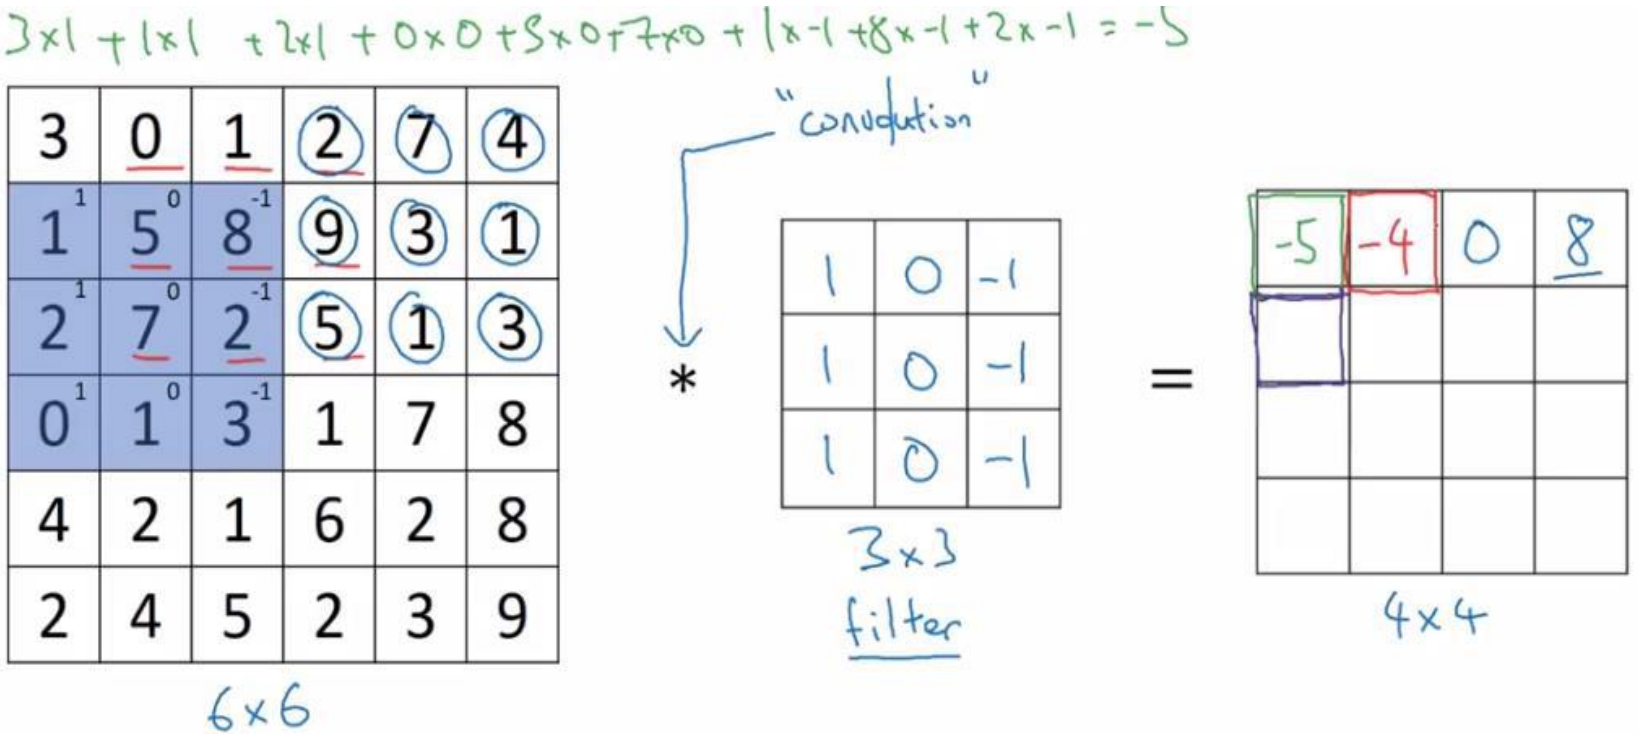
$$i(1,1) = (-1x55) + (-1x75) + (-1x77) + (-2x48) + (10x70) + (-2x83) + (-1x51) + (-1x68) + (-1x85) = 32$$



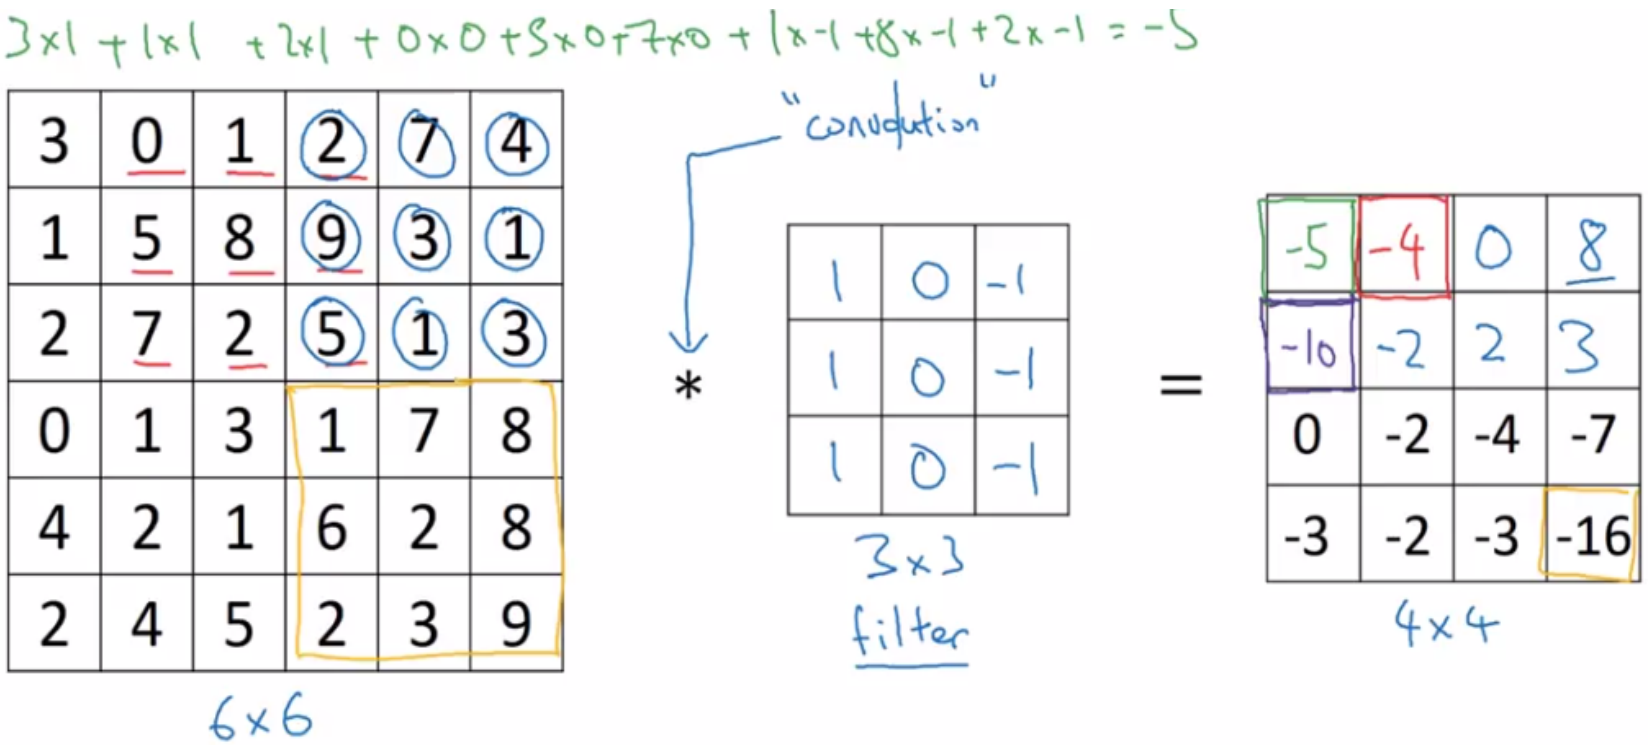
Konvolüsyon ile Boyut Küçültme



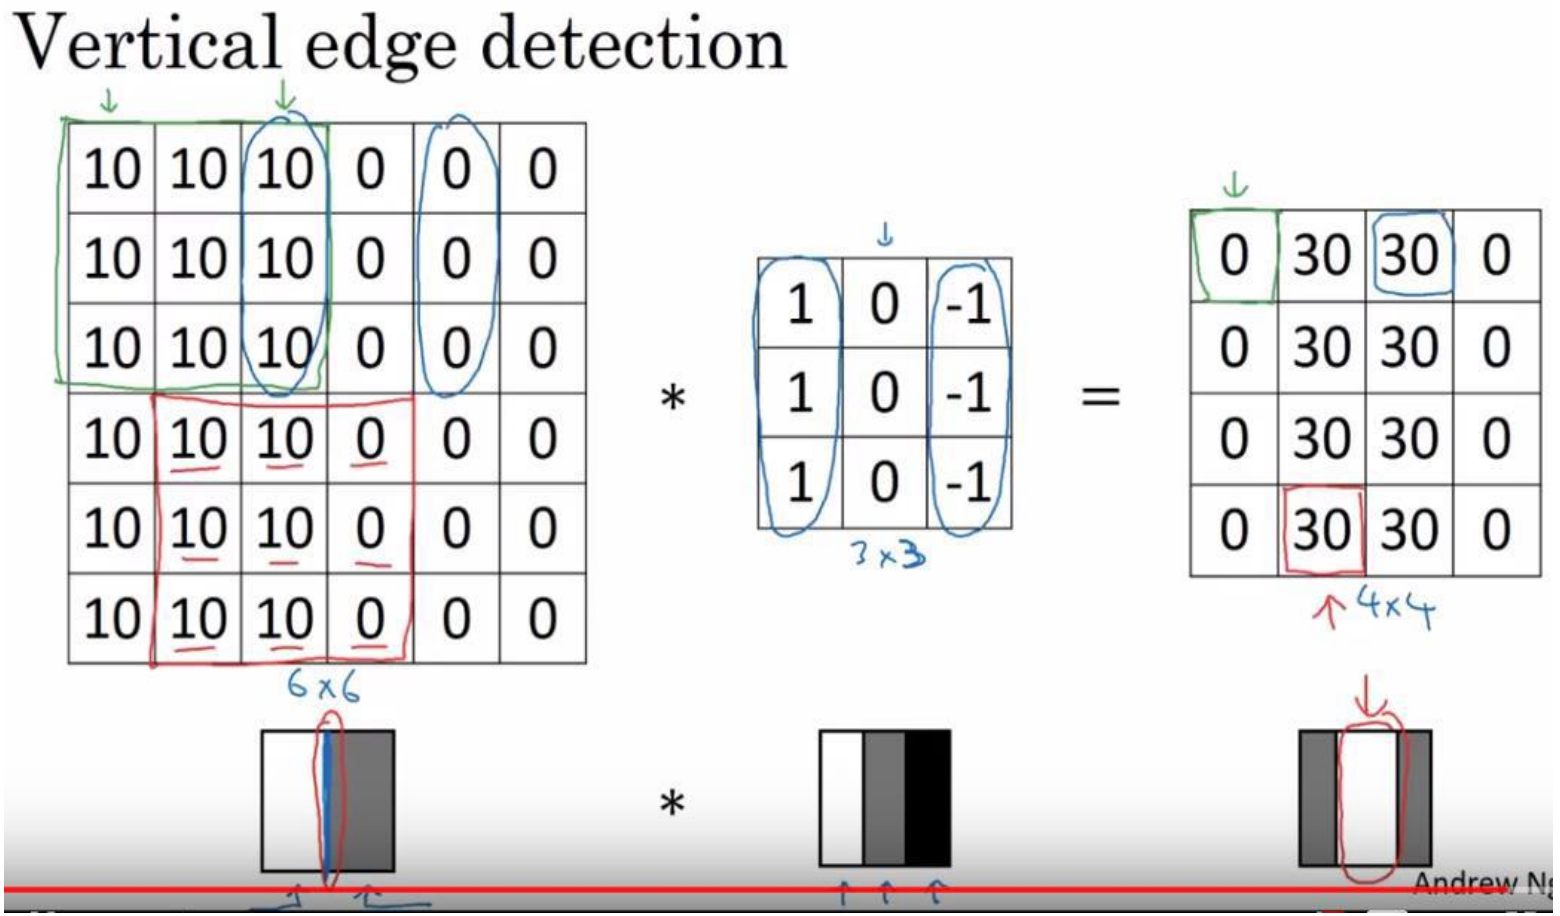
Konvolüsyon ile Boyut Küçültme



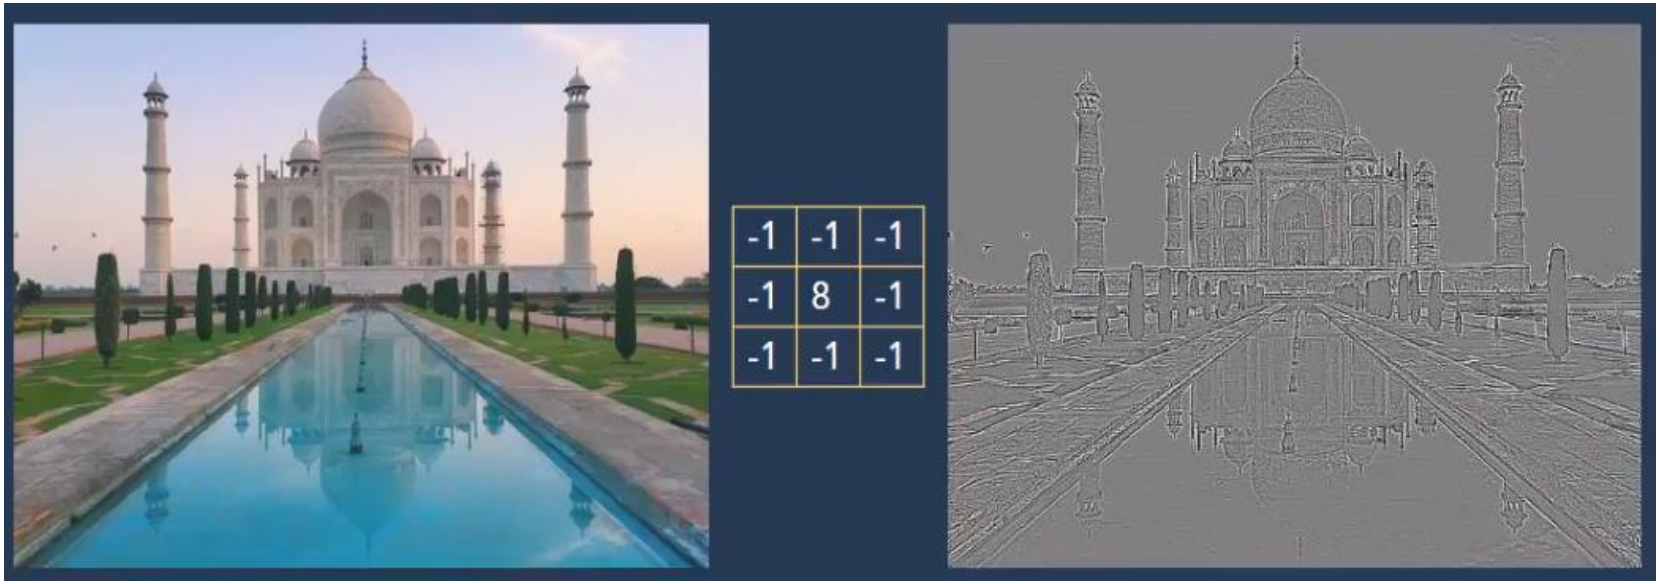
Konvolüsyon ile Boyut Küçültme



Konvolüsyon ile Kenar Belirleme

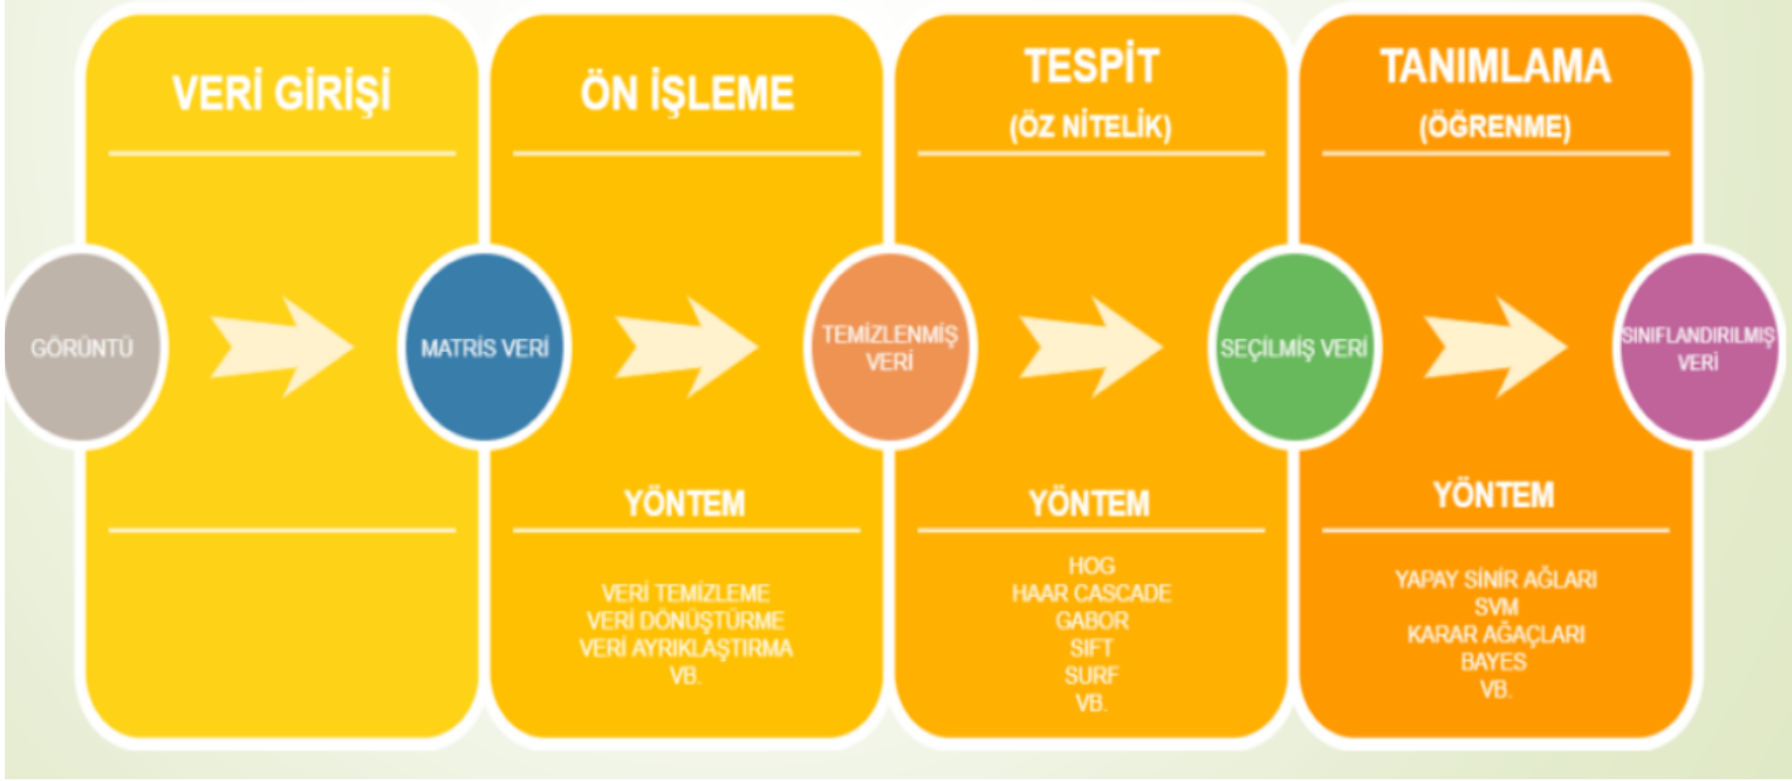


Konvolüsyon ile Kenar Belirleme



Görüntü İşleme Aşamaları

Görüntü işleme, ölçülmüş ve kaydedilmiş olan dijital görüntü verilerini elektronik ortamda amaca uygun bir şekilde değiştirmek, iyileştirmek, spesifik görüntü elde etmek veya bazı yararlı bilgiler elde etmek için yapılan çalışmaların tamamı olarak adlandırılabilir.



Projeksiyon (Projection) Kavramı

Projeksiyonlarda belirlenen bir **doğrultuda resim taranarak piksel sayıları tespit edilir.** Histogram'dan farklı olarak **genellikle eşiklenmiş veya ikili resimler üzerinde işlem gerçekleştirilir.** En sık kullanılan projeksiyonlar **yatay ve dikey projeksiyonlardır.** Bu projeksiyonlar sırasıyla 0° ve 90° lik doğrultuda beyaz piksellerin sayısını gösterir grafikleri üretirler. Projeksiyonlarda bir vektör olup hangi aralıkta piksel sayımı gerçekleştiriliyorsa o vektörün uzunluğu da toplam tarama alanının bu aralık değerine bölümü ile bulunur. Genelde bir piksel aralığında sayım yapıldığı düşünülürse vektörün uzunluğu, yatay projeksiyonda görüntünün genişliğini ifade eden piksel sayısını, dikey projeksiyonda ise görüntünün yüksekliğini ifade eden piksel sayısını temsil eder.

Yatay ve dikey projeksiyonun dışında **görüntü tanıma** algoritmalarında kullanılan **daha pek çok projeksiyon vardır.** Teorik olarak çok küçük açı farkları ile projeksiyonlar elde edilebilir. ***Projeksiyon vektörleri de histogram vektörleri*** **gibi doğrudan tanıma algoritmalarında kullanılırlar.** Fakat bir görüntüyü temsil eden tek bir histogram vektörü var iken pek çok projeksiyon vektörü de mevcuttur. Bu nedenle kullanılacak projeksiyon vektörleri uç uca eklenerek tek bir vektör elde edildikten sonra tanıma algoritmalarına uygulanabilirler.

Projeksiyon (Projection) Kavramı

Histogram ve projeksiyon vektörleri kendi başlarına **bir görüntünün öznitelikleridir (görüntüden renk ve şekil gibi yüksek düzeyde bilgilerin çıkarılması).** Fakat tanıma algoritmalarında sahip oldukları **boyut fazlalığı nedeniyle yavaşlamaya** sebep olurlar. Bu vektörlerin de öznitelikleri elde edilerek aynı görevi yerine getirecek daha az sayıda veri içeren öznitelik vektörleri elde edilebilir. Bu amaçla istatistik, PCA (Principal Component Analysis), FCM (Fuzzy C Means) ve bunların dışında bazı öznitelik detektörleri kullanılabilir. PCA ve FCM'nin kullanılmasında diğer uygulamalardan farklı bir durum söz konusu değildir. Fakat istatistik öznitelikler farklılık arz eder. Tek boyutlu veriler için ortalama, varyans (tüm değerlerin ortalama değerden olan farklarının karelerinin ortalaması) ve standart sapma (varyansın karekökü) gibi istatistik öznitelikleri veren denklemleri aşağıda verilmiştir. Bu denklemlere ek olarak ortanca değer (verilerin sıralanmasını neticesinde tam ortada kalan değer) ve mod (bir gurup veride ençok tekrarlanan değeri) değerinin bulunması da istatistik öznitelikleri verir.

$$Ortalama = \bar{x} = \frac{1}{N}\sum_{i=1}^{N} x_i$$

$$standart\ sapma \Leftarrow \sigma = varyans = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(x_i - \bar{x})^2}$$

Görüntü Tanıma-Analiz

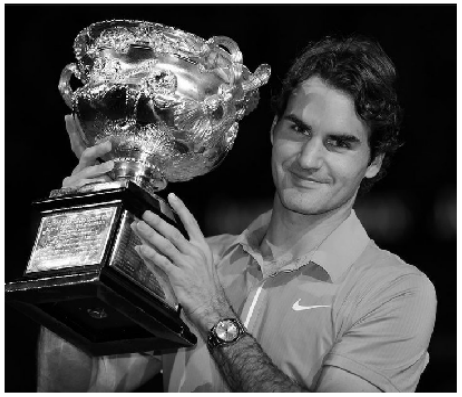
- İstatistik öznitelikler, segmentasyon, kenar ve çizgilerin çıkarımı, histogram ve projeksiyonlar, PCA (Principal Component Analysis Temel Bileşenler Analizi), FCM (Fuzzy C Means Bulanık C Ortalama), SOM (Self Organizing Map Özdüzenlemeli (kendi kendini düzenleyen) Ağ), Sezgisel Algoritmalar (yapay sinir ağları, genetik algoritmalar vb. **öznitelik tespitinde kullanılan metotlardır.**
- Görüntü tanıma, bir resim üzerinde pek çok **ön işleme** ve **öznitelik çıkarımı** işlemleri ardından elde edilen sonuç vektörleri kullanarak görüntüde neyin olup neyin olmadığına karar vermek demektir. Genel bir tanıma veya ne olursa olsun tanıma şeklinde gerçekleşmeyen tanıma süreci, problemin ihtiyacı doğrultusunda özelleştirilerek kullanılır. Bazı problemlerde belli sayıdaki nesnelerden hangisinin görüntüde olduğu veya olmadığı şeklinde bir tanıma süreci istenirken, bazı problemlerde de ortam veya geri plan haricindeki görüntüde herhangi bir nesnenin olup olmadığı, şayet varsa onun konumu hakkında bilgi üreten bir tanıma sürecine ihtiyaç duyulur.

Segmentasyon Kavramı

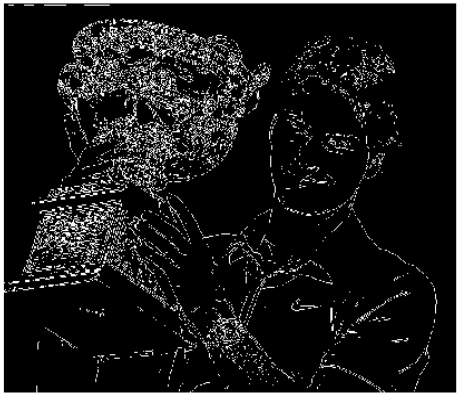
- **Ayıklama** veya **bölütleme** anlamı da taşıyan **segmentasyon** kelimesi, **bir resmin içindeki bir bütün oluşturan parçaların arka plandan veya diğer nesnelerden ayrılması işlemidir.**
- Görüntüde bir nesnenin varlığından söz edebilmek için görüntünün diğer parçalarından **ayırt edilebilir bir özelliğinin** olması ve bunun nesnenin tümü için geçerli olması gerekir.
- En temel farklılık görüntüdeki **parlaklıktır.** Parlaklıktaki farklılığa dayalı bir segmentasyon işlemi **eşikleme** operatörü ile gerçekleştirilir. Adaptif eşikleme algoritmaları da bu amaçla kullanılabilirler.
- Diğer bir farklılık ise **renklerde veya desenlerde olan farklılıklardır. Renklerde** olan farklılıklara göre yapılan segmentasyon işlemi genelde **renk uzayları arasında dönüşüm gerektirir**. Bu segmentasyon işlemi için en çok CIELAB renk uzayı kullanılır.
- **Desenlerdeki** farklılıkların tespiti ise daha zordur. Desenlerde bulunan tekrarların tespitinde Fast Fourier Transform (FFT), Wavelet (dalgacık) gibi dönüşümler benimsenirken diğer tanımlamalar istatistik analiz ile elde edilir.

Segmentasyon (Bölütleme)

Original Image



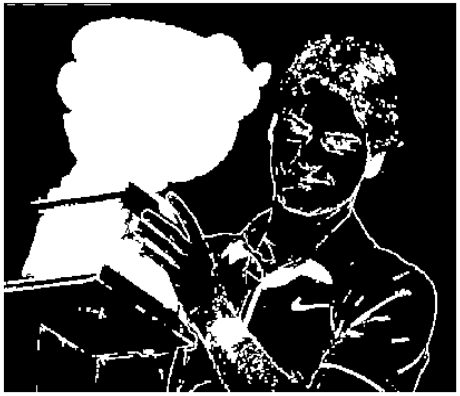
Binary gradient mask



Dilated gradient mask



Binary image with filled holes

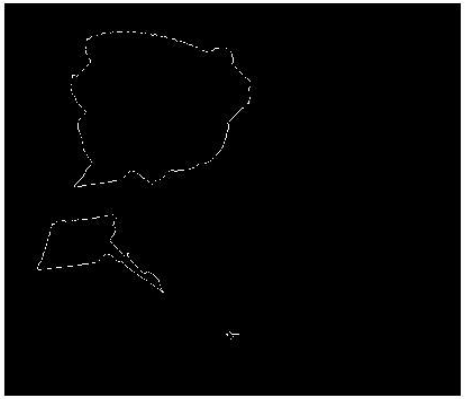


Segmentasyon (Bölütleme)

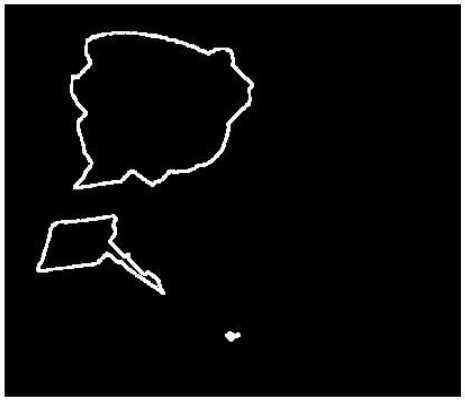
Segmented Image



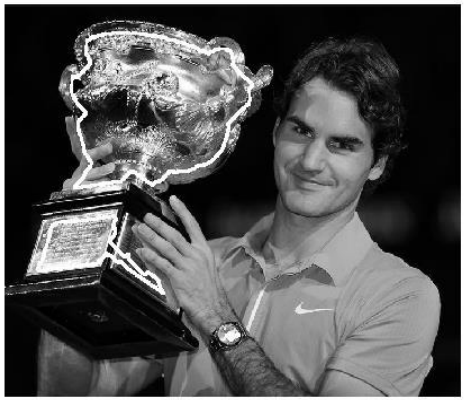
Outline Segmentation



Dilate



Outlined Original Image



Segmentasyon (Bölütleme)



Segmentasyon (Bölütleme)

```
clear all;
close all;
clc;
I = imread('rice.png');
background = imopen(I, strel('disk', 15));
C=imsubtract(I,background);
figure;
subplot(1,3,1); imshow(I); title('Resmin Orjinali');
subplot(1,3,2); imshow(background); title('Resmin Zemini');
subplot(1,3,3); imshow(C); title('Resmin Zemini Çıkarılması');
```

Segmentasyon (Bölütleme)

strel : Morfolojik yapısal element yaratır

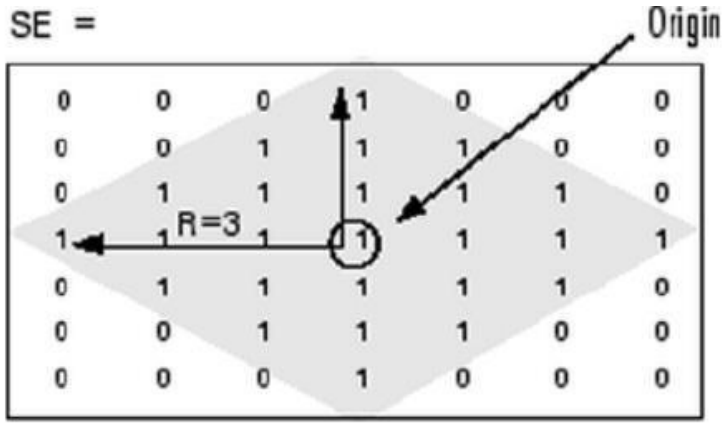
SE = strel(*shape*, parameters)

structural element

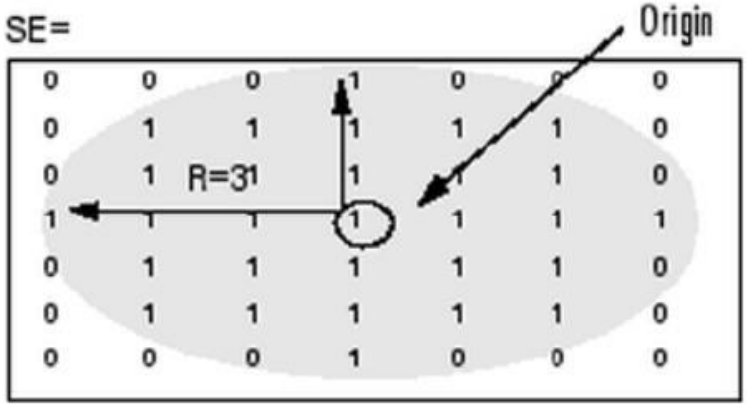
Desteklenen şekiller

'arbitrary'	'pair'
'diamond'	'periodicline'
'disk'	'rectangle'
'line'	'square'
'octagon'	

'arbitrary'	'ball'



SE = strel('diamond', 3)



SE = strel('disk', 3, 0)

Segmentasyon (Bölütleme)

Image **Segmentation**, **yapısal olmayan görüntüden bir yapısal görünüm ortaya çıkartmaya** çalışır.
Image segmentation'ın **en büyük problemi** nesnenin **sınırlarının bulunmasıdır.** Bu hemen akla **edge detection** konusu getirir. Ama iki problemi de beraberinde getirir.

Gürültüler?
Yerel hatlar?

Görüntü **segmentasyonu**, ilgili görüntü yapısının **zeminden (arka plandan) ve diğer görüntü bileşenlerinden ayrılması** işlemidir.
Segmentasyon işleminde temel amaç, **bir veya birden fazla karakteristik veya özelliğe uygun olarak, görüntünün bölümlere (sınıflara veya alt kümelere) ayrılması işlemidir.**
Bu işlem için görüntü işleme alanında oldukça çok sayıda algoritma geliştirilmiştir.

Segmentasyon (Bölütleme)

Segmentasyon teknikleri aşağıdaki gibi sınıflandırılabilir :

- Manuel, yarı otomatik ve otomatik,
- Piksel tabanlı (yerel metotlar) ve alan tabanlı (global metotlar),
- Manuel tarif, düşük seviyeli segmentasyon eşikleme alan geliştirme vb. ve model tabanlı segmentasyon (özellik haritalama teknikleri, dinamik programlama, kontur takibi vs.
- Klasik (eşikleme kenar tabanlı ve alan tabanlı teknikler), istatistiksel, bulanık ve sinir ağı teknikleri

Segmentasyon (Bölütleme)

Ortak kullanılan segmentasyon teknikleri iki geniş kategoriye ayrılabilirler:

- Verilen homojenite kriterine uygun alanlar arama esasına dayanan **alan segmentasyon teknikleri**
- Farklı karakteristikler ile alanlar arasında sınırlar (kenarlar) arayan **kenar tabanlı segmentasyon teknikleri**

Segmentasyon (Bölütleme)

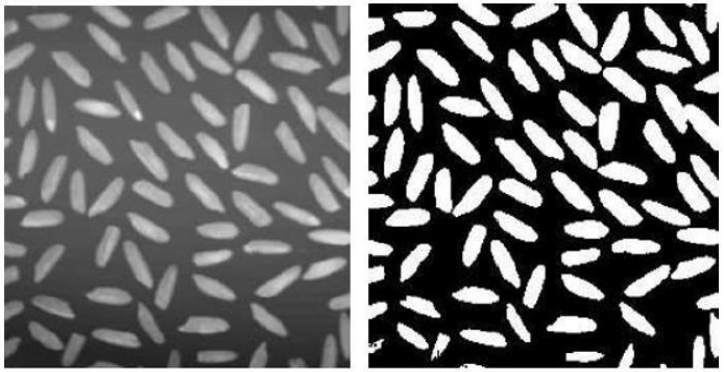
Özet olarak, segmentasyon 2 önemli başlık altında incelenir.

- Eşikleme (Thresholding)
- Kenar Bulma (Edge Detection)

Eşikleme (Thresholding)

Eşikleme *nesnelerin arka plandan ayrılması* işlemidir ve en basit *bölütleme (segmentation) yöntemidir.* Nesneleri arka plandan ayırmak için en kolay yol, histogramdan göreceli olarak belirlenen bir T eşik değeri ile görüntüdeki piksel değerlerini karşılaştırmak olacaktır. Buna göre, görüntüdeki herhangi bir (i, j) pikseli için; f(i, j) > T ise (i, j) pikseli nesneye ait bir nokta, f(i,j) ≤ T ise (i, j) pikseli arka plana ait bir nokta olacaktır.

$$yeniresim(x,y) = \begin{cases} 0 \text{ eğer } resim(x,y) < T \\ 255 \text{ eğer } resim(x,y) > T \end{cases}$$



Eşikleme (Thresholding)

Eşikleme yöntemleri;

- **Bütünsel Eşikleme Yöntemleri** (Global Binarization Methods)
- **Yerel Uyarlamalı (Dinamik) Eşikleme Yöntemleri** (Locally Adaptive Binarization Methods)

olmak üzere ikiye ayrılır.

Eşikleme (Thresholding)

Bütünsel Global Eşikleme yöntemleri tüm görüntü için **tek bir eşik** (threshold) değeri hesaplar. Bütünsel eşikleme bazı tür görüntülerde olumlu sonuç verse de, bu yöntemlerin en belirgin eksikliği sadece **tüm görüntüdeki piksellerin gri seviye değerlerini** göz önüne alıyor olmalarıdır. Bütünsel eşikleme, görüntünün her bir bölgesinde farklı bir eşik değer kullanma gereksinimini, piksellerin yerleşimini ve aralarındaki yerel ilişkilerini hesaba katmazlar. Bundan dolayı sonraki aşamalarda birtakım hatalarla karşılaşmak mümkün hale gelmektedir.

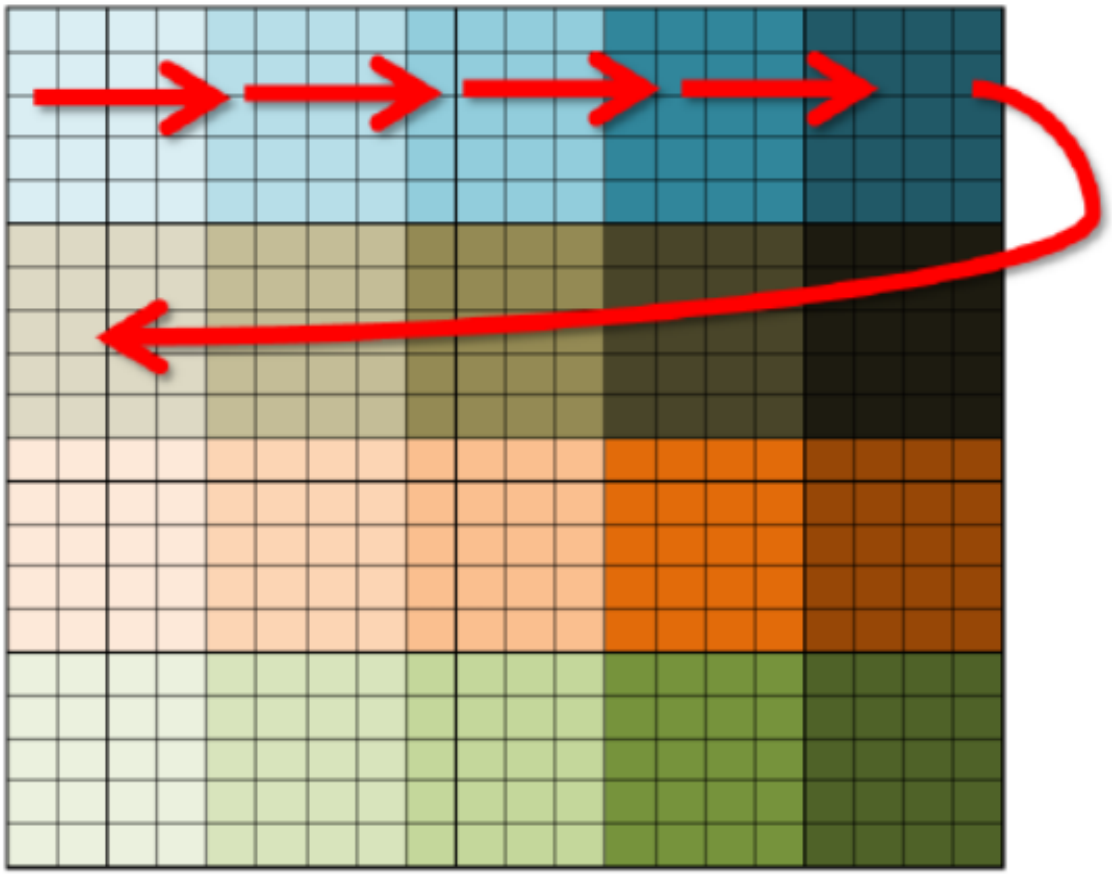
Eşikleme (Thresholding)

Yerel-Lokal uyarlamalı **dinamik eşiklemede** görüntü üzerinde bir piksel grubu (matris) gezdirilerek eşik değer belirlemenin yapılması prensibine dayanmaktadır. Eşik değerin belirlenmesindeki en yaygın yöntem, gezdirilen matris içerisindeki gri değerlerin ortalamasını almak ve belirlenen ortalamayı eşik değer olarak kullanmaktır. İşlem aynı şekilde tüm görüntüye uygulanır. Gürültü olmayan, tekdüze bir arka fona sahip bir görüntüde bu yöntem başarılı olabilir.

Eğer T hem f(x,y) hem de p(x,y)'ye bağlı ise bu durumda, T denklemindeki eşik değeri bölgesel (local) eşik olarak adlandırılır.

$$T = T\,[x, y, f(x,y), p(x,y)] \qquad g(x,y) = \begin{cases} 1; \text{eğer } f(x,y) > T \\ 0; \text{eğer } f(x,y) < T \end{cases}$$

Eşikleme (Thresholding)



Lokal Eşikleme Sırası

Eşikleme (Thresholding)

- **Yerel Uyarlamalı** eşikleme yöntemleri «**bir pikselin komşuluğundaki bilgileri» temel alarak her bir piksel için bir eşik değeri hesaplar.** Bazı yöntemler tüm görüntü üzerinde bir eşik değeri hesaplar.
- Bu metotlardan bazıları aşağıdadır.

Bernsen's Method	Chow and Kaneko's Method	Eikvil et al.'s Method
Mardia and Hainsworth's Method	Niblack's Method	Niblack's Method
Yanowitz and Bruckstein's Method	Parker's Method	White and Rohrer's Dynamic Threshold Algorithm
White and Rohrer's Integrated Function Algorithm	Trier and Taxt's Method	

Eşikleme (Thresholding)

Tek Eşikleme

- Gri ölçekli bir görüntü, bir T eşik değeri seçilerek siyah-beyaz (binary) görüntü haline dönüştürülür.
- T değerine bakılarak her bir pikselin değeri "0" veya "1" olarak ifade edilir.

$$\text{A pixel becomes} \begin{cases} \text{white if its grey level is} > T, \\ \text{black if its grey level is} \leq T. \end{cases}$$

- Eşikleme, görüntü segmentasyonunun en hayati parçasıdır.
- Robotik görme işlemleri için en önemli bileşenlerden birisidir.

Eşikleme (Thresholding)

Tek Eşikleme

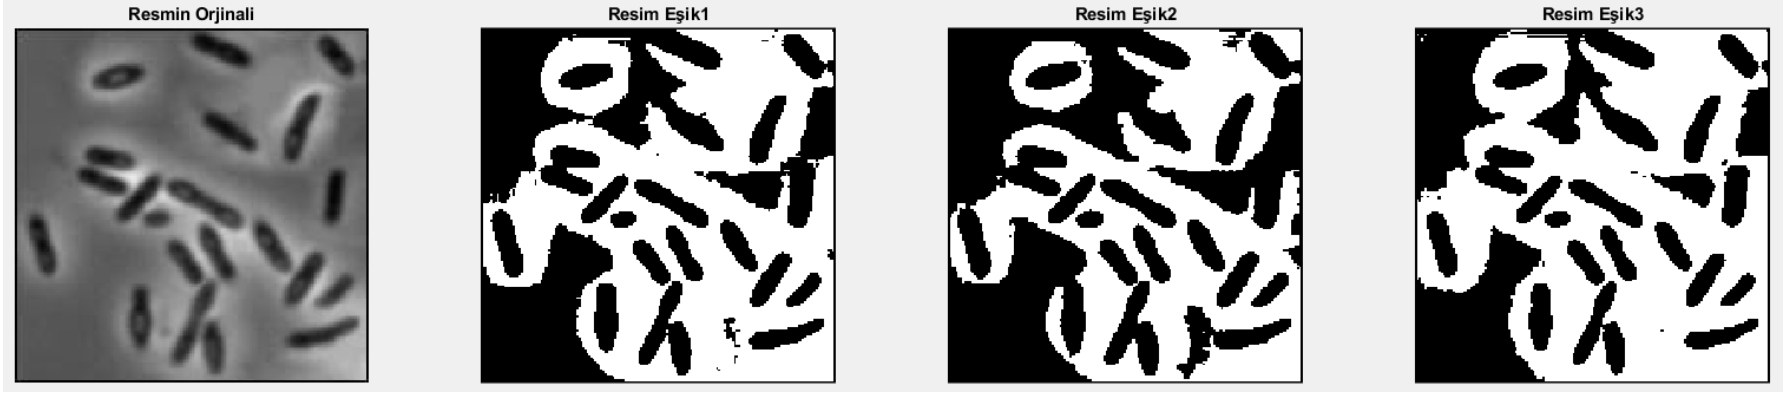
```
clear all, close all,clc;
I = imread('rice.png');
level=graythresh(I);
bw=imbinarize (I,level);
It = I>125;
figure;
subplot(1,3,1); imshow(I); title('Resmin Orjinali');
subplot(1,3,2); imshow(bw); title('Resim Eşik1');
subplot(1,3,3); imshow(It); title('Resim Eşik2');
```



Eşikleme (Thresholding)

Tek Eşikleme

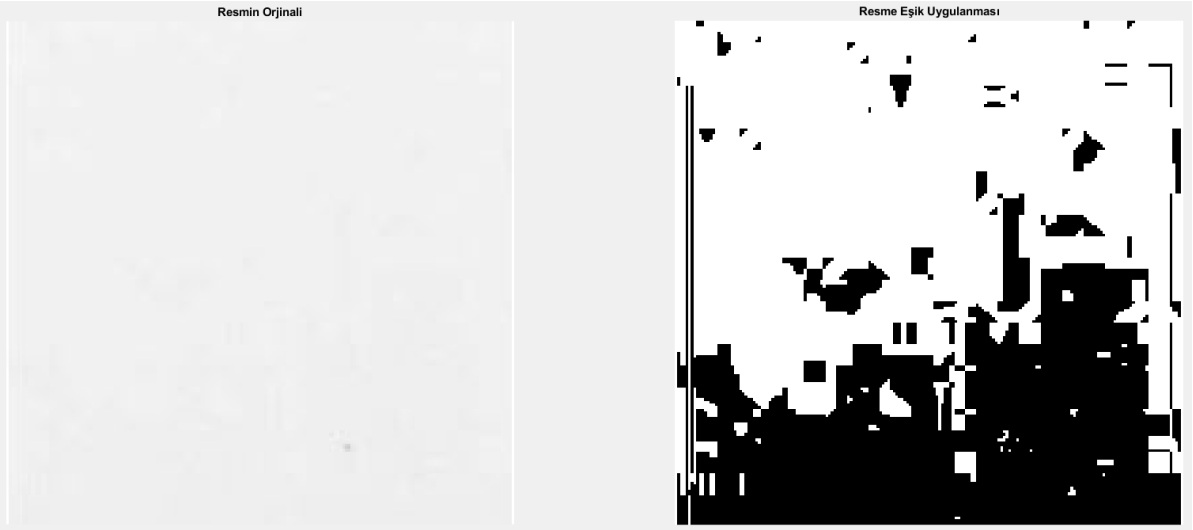
```
clear all, close all,clc;
I = imread("C:\Users\asus\Desktop\bacteria.jpg");
I=rgb2gray(I);
I2=imbinarize (I);
I3=imbinarize (I,0.43);
I4=imbinarize (I,0.39);
figure;
subplot(1,4,1); imshow(I); title('Resmin Orjinali');
subplot(1,4,2); imshow(I2); title('Resim Eşik1');
subplot(1,4,3); imshow(I3); title('Resim Eşik2');
subplot(1,4,4); imshow(I4); title('Resim Eşik3');
```



Eşikleme (Thresholding)

Tek Eşikleme

```
clear all, close all,clc;
A = imread("paper.jpg");
I=rgb2gray(A);
II= (I>240);
figure;
subplot(1,2,1); imshow(I); title('Resmin Orjinali');
subplot(1,2,2); imshow(II); title('Resme Eşik Uygulanması');
```



Eşikleme (Thresholding)

Çift Eşikleme

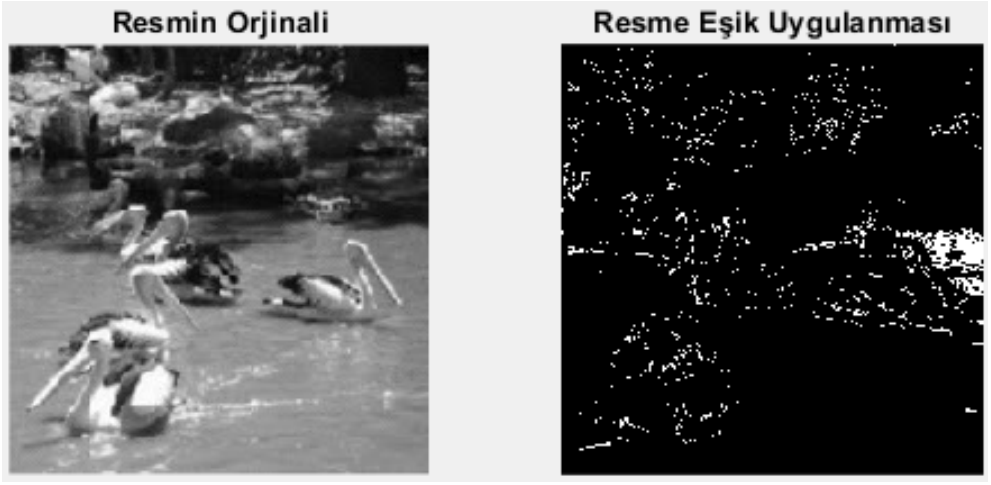
T1 ve T2 gibi iki değer seçilerek eşikleme işlemi yapılır.

$$\text{A pixel becomes} \begin{cases} \text{white if its grey level is between } T_1 \text{ and } T_2, \\ \text{black if its grey level is otherwise.} \end{cases}$$

Eşikleme (Thresholding)

Çift Eşikleme

```
clear, close all,clc;
A = imread('D:\resler\pelicans.png');
I=rgb2gray(A);
II= (I>115&I<125);
figure;
subplot(1,2,1); imshow(I); title('Resmin Orjinali');
subplot(1,2,2); imshow(II); title('Resim Eşik');
```



Eşikleme (Thresholding)

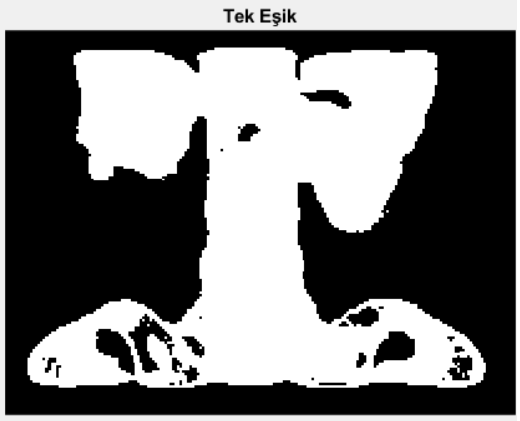
Çift Eşikleme

```
clear, close all,clc;
s=imread('spine.jpg');
s=rgb2gray(s);
IT1=(s>115 & s<125);
IT2=(s>115);

subplot(1,3,1), imshow(s), title('Resmin Orjinali')
subplot(1,3,2), imshow(IT1), title('Çift Eşik')
subplot(1,3,3), imshow(IT2), title('Tek Eşik')
```

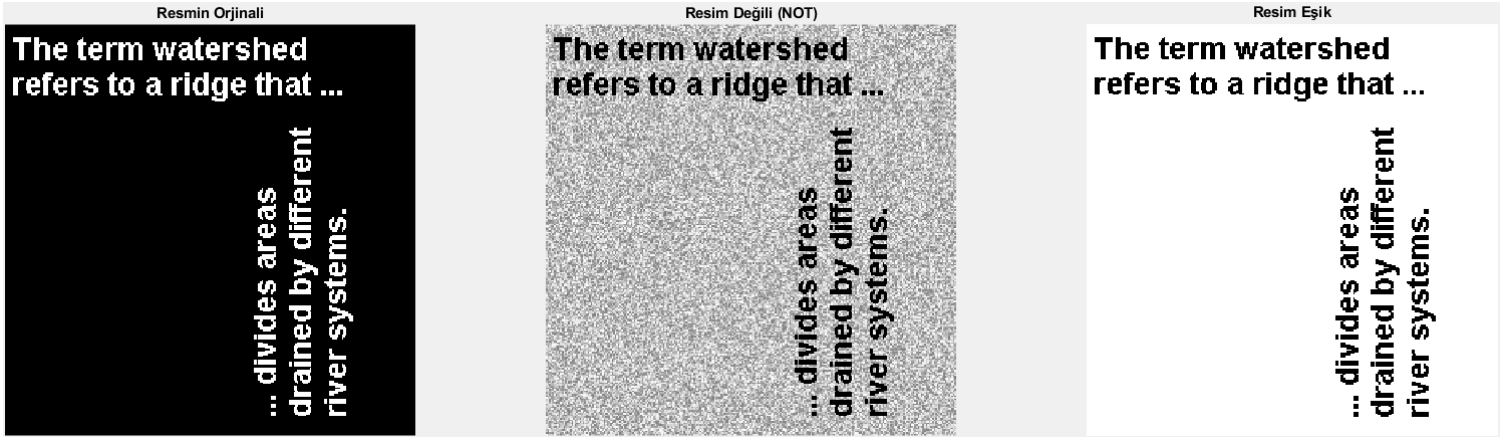






Eşikleme Uygulamaları

```
clear, close all,clc;
r=rand(256)*128+127;
I = imread('text.png');
% I=rgb2gray(A);
II= uint8(r.*double(not(I))); %not komutu metni beyaz arkaplan siyah yazı olarak değiştirir
III= (II>100);
figure;
subplot(1,3,1); imshow(I); title('Resmin Orjinali');
subplot(1,3,2); imshow(II); title('Resim Değili (NOT)');
subplot(1,3,3); imshow(III); title('Resim Eşik');
```

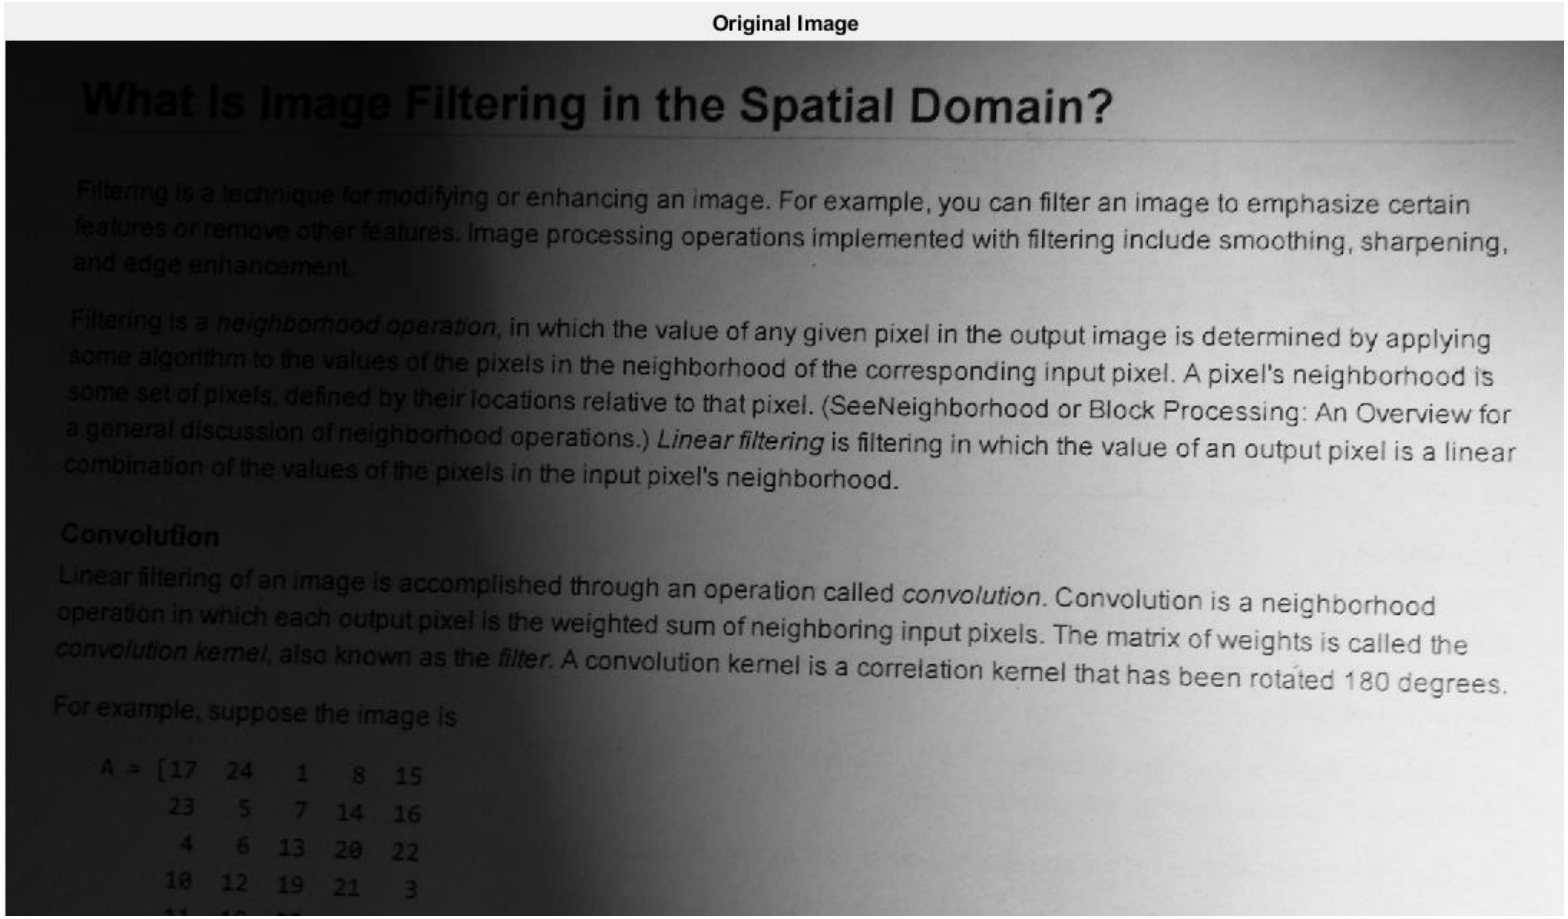


Eşikleme Uygulamaları

Eşikleme işlemleri aşağıdaki durumlar için uygundur.

- Bir **görüntüden gereksiz detayların uzaklaştırılması**. **Pirinç** ve **bakteri** örneklerinde olduğu gibi.
- **Gizli detayları ortaya çıkarmak.** Beyaz kağıt örneğinde olduğu gibi.
- **Arkaplanı, metin veya çizimden ayırt etmek** için kullanılır.

Eşikleme Uygulamaları



Eşikleme Uygulamaları

Binary Version of Image

What Is Image Filtering in the Spatial Domain?

Filtering is a technique for modifying or enhancing an image. For example, you can filter an image to emphasize certain features or remove other features. Image processing operations implemented with filtering include smoothing, sharpening, and edge enhancement.

Filtering is a *neighborhood operation*, in which the value of any given pixel in the output image is determined by applying some algorithm to the values of the pixels in the neighborhood of the corresponding input pixel. A pixel's neighborhood is some set of pixels, defined by their locations relative to that pixel. (SeeNeighborhood or Block Processing: An Overview for a general discussion of neighborhood operations.) *Linear filtering* is filtering in which the value of an output pixel is a linear combination of the values of the pixels in the input pixel's neighborhood.

Convolution

Linear filtering of an image is accomplished through an operation called *convolution*. Convolution is a neighborhood operation in which each output pixel is the weighted sum of neighboring input pixels. The matrix of weights is called the *convolution kernel*, also known as the *filter*. A convolution kernel is a correlation kernel that has been rotated 180 degrees.

For example, suppose the image is

```
A = [17  24   1   8  15
     23   5   7  14  16
      4   6  13  20  22
     10  12  19  21   3
```

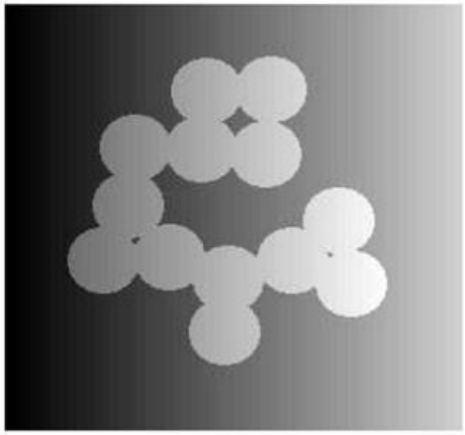
Eşikleme Uygulamaları

```
clear all, close all,clc;
I = imread('printedtext.png');
figure
imshow(I)
title('Original Image')
BW = imbinarize(I,'adaptive','ForegroundPolarity','dark','Sensitivity',0.4);
figure
imshow(BW)
title('Binary Version of Image')
```

Adaptif Eşikleme

Bazı durumlarda tek bir eşik değerinin belirlenmesi tüm görüntünün eşikten geçirilmesi için yeterli olmayabilir.

Arka planın değiştiği durumlarda adaptif bir eşiklemeye ihtiyaç duyulmaktadır.



$$yeniresim(x,y) = \begin{cases} 0 \text{ eğer } resim(x,y) < T \\ 255 \text{ eğer } resim(x,y) > T \end{cases}$$

Adaptif Eşikleme

$$yeniresim(x,y) = \begin{cases} 0 \text{ eğer } resim(x,y) < T \\ 255 \text{ eğer } resim(x,y) > T \end{cases}$$

Burada **T** değe r **T** değeri çok büyük seçilirse oluşturulacak yeni görüntüde pek çok piksel beyaz(1), küçük seçilirse de siyah(0) olacağından görüntünün içerdiği bilgi ciddi miktarda azalacaktır. Birkaç resim için ideal eşik değeri **deneme** yoluyla bulunabilse de farklı ışık ortamlarında çekilmiş çok sayıda görüntü için bu söz konusu olamaz. Bu nedenle girdi resmine karşılık **eşik değerini otomatik** olarak hesaplayan bir algoritma gerekmektedir. *Nobuyuki Otsu* (1979) tarafından geliştirilen Otsu Metodu ile eşik değeri görüntü üzerinden hesaplanmaktadır. Metot, görüntü üzerinde iki ayrı sınıf (plan) olduğunu kabul ederek, bu iki sınıf arasındaki varyansı maksimum yapacak değeri bulmaya çalışır. Varyans, bir dizinin elemanlarının dizinin ortalamasına olan uzaklıklarının karelerinin ortalamasıdır. Bu değere bakarak dizi içerisindeki değerlerin ortalamaya ne derece yakın olduğu görülebilir. Aşağıda N uzunluklu bir dizi için varyans hesaplama formülü verilmiştir.

$$Ortalama = \bar{x} = \frac{1}{N}\sum_{i=1}^{N} x_i$$

$$varyans = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(x_i - \bar{x})^2}$$

Adaptif Eşikleme

$$\sigma^2 = \sum_{i=0}^{N-1}(x_i - \mu_x)Pr\{x_i\}$$

Yukarıdaki ifadede Pr{xi} ifadesi xi'nin gelme olasılığıdır. Düzgün dağılımlı N uzunluklu bir dizi için bu değer 1/N dir. M×N bir görüntü için konuşacak olursak, histogram dizisi hesaplandıktan sonra, i tonunun gelme olasılığı histogram[i]/(MxN) dir.
Sınıflar arası varyans (siyah-beyaz sınıfları) aşağıdaki formül ile bulunur.

$$\sigma_s = \sigma - \sigma_b = \omega_1(t)\omega_2(t)(\mu_1(t) - \mu_2(t))$$

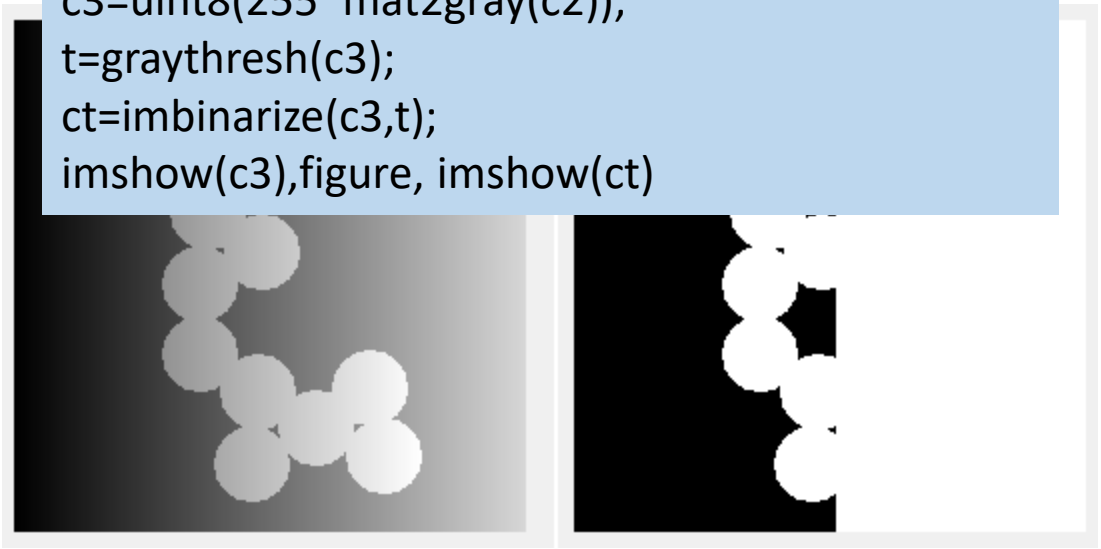
Burada ω değişkenleri sınıf yoğunluklarını, μ değişkeleri ise ağırlıklı sınıf ortalamalarını göstermektedir ve X(i) i.renk seviyesidir. Bu değerler aşağıdaki formüller yardımıyla hesaplanır.

$$\omega_1(t) = \sum_{i=0}^{t} Pr\{i\} \quad \omega_2(t) = \sum_{i=t+1}^{255} Pr\{i\}$$

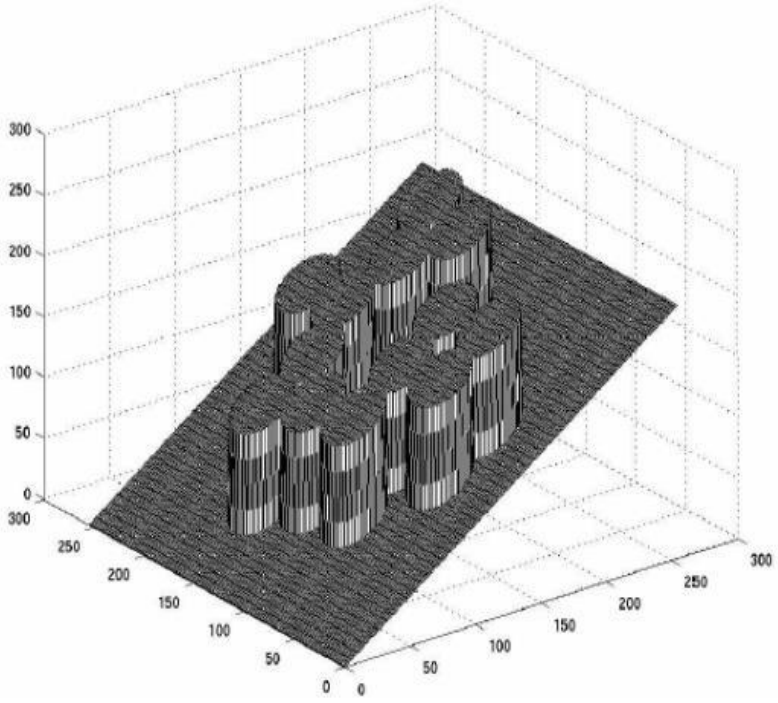
$$\mu_1(t) = \sum_{i=0}^{t} Pr\{i\}X(i) \quad \mu_1(t) = \sum_{i=t+1}^{255} Pr\{i\}X(i)$$

Adaptif Eşikleme

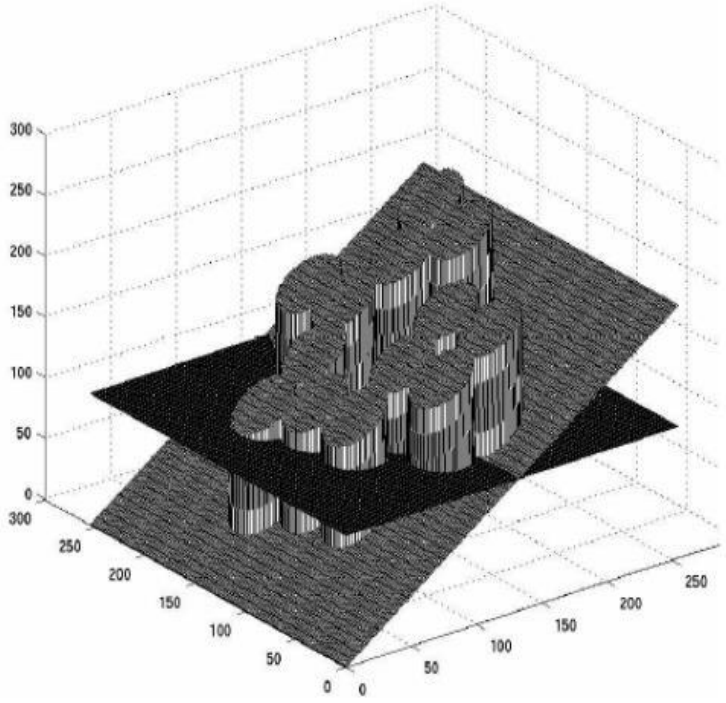
```
clear all, close all,clc;
c=imread('circles.png');
x=ones(256,1)*[1:256];
c2=double(c).*(x/2+50)+(1-double(c)).*x/2;
c3=uint8(255*mat2gray(c2));
t=graythresh(c3);
ct=imbinarize(c3,t);
imshow(c3),figure, imshow(ct)
```



Adaptif Eşikleme



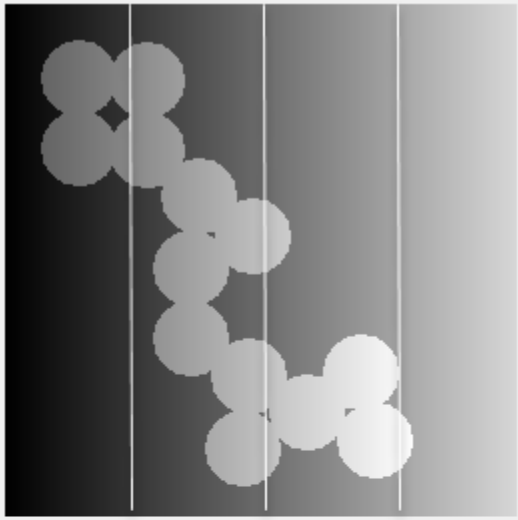
Bir fonksiyon olarak görüntü

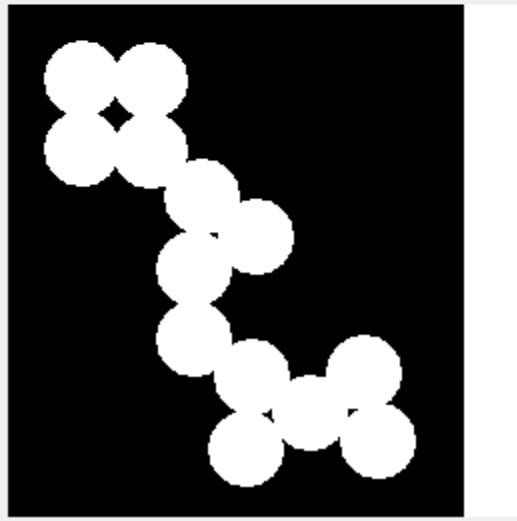


Eşikleme

Adaptif Eşikleme

```
clear all, close all,clc;
c=imread('circles.png');
x=ones(256,1)*[1:256];
c2=double(c).*(x/2+50)+(1-double(c)).*x/2;
c3=uint8(255*mat2gray(c2));
p1=c3(:,1:64);
p2=c3(:,65:128);
p3=c3(:,129:192);
p4=c3(:,193:256);
g1=imbinarize(p1,graythresh(p1));
g2=imbinarize(p2,graythresh(p2));
g3=imbinarize(p3,graythresh(p3));
g4=imbinarize(p4,graythresh(p4));
imshow([p1 p2 p3 p4]), figure, imshow([g1 g2 g3 g4])
```







TEŞEKKÜRLER